

ACTIVIDAD 2 · UNIDAD 1 · APRENDIZAJE BASADO EN RETOS

Diseño de un algoritmo de aprendizaje profundo para la detección automática de defectos en productos de panadería y pastelería

Una propuesta basada en redes neuronales convolucionales con transfer learning, fundamentada en evidencia empírica del sector alimentario y orientada a la producción artesanal en Bucaramanga, Santander.

ESTUDIANTE Angélica Saraith Herrera Osorio

DOCENTE José Fabián Díaz Silva

FECHA Abril 28 de 2026 · Bucaramanga, Santander, Colombia

ESTRATEGIA PEDAGÓGICA Aprendizaje Basado en Retos (ABR)

Tabla de contenidos

01 Resumen y palabras clave	3
02 Identificación y justificación del problema	3
2.1 Contexto del sector panadero-pastelero en Colombia	3
2.2 Formulación del problema	4
2.3 Justificación e impacto esperado	5
03 Revisión bibliográfica	6
3.1 Redes neuronales convolucionales en inspección alimentaria	6
3.2 Transfer learning y arquitecturas EfficientNet	7
3.3 Consideraciones éticas y de equidad algorítmica	8
04 Diseño del algoritmo	9
4.1 Arquitectura general del sistema	9
4.2 Datos de entrada y preprocesamiento	10
4.3 Arquitectura de la red neuronal	11
4.4 Funciones de activación y optimización	12
4.5 Pseudocódigo del entrenamiento	13
05 Implementación y plan de pruebas	14
06 Evaluación crítica y reflexión	15
07 Conclusiones	16
08 Referencias bibliográficas	17

RESUMEN

En la mayoría de las panaderías y pastelerías artesanales de Bucaramanga, decidir si una pieza sale a la vitrina o se devuelve al horno todavía depende del ojo del panadero. Eso funciona bien cuando hay tres o cuatro hornadas al día, pero deja de funcionar en hora pico, cuando los turnos se alargan o el personal rota.

Este trabajo propone el diseño de un algoritmo de aprendizaje profundo basado en redes neuronales convolucionales, con transferencia de conocimiento desde EfficientNet-B0 preentrenada en ImageNet, para clasificar productos horneados como aptos o defectuosos e identificar el tipo de defecto. La elección del problema parte de mi propia experiencia de cuatro años en el oficio.

La revisión bibliográfica cubre publicaciones entre 2021 y 2025 y respalda cada decisión técnica del diseño: arquitectura, aumento de datos, regularización por *dropout*, optimizador Adam con tasa adaptativa y métricas robustas como precisión, *recall* y F1-score. El diseño también recoge los principios de la *Recomendación sobre la ética de la inteligencia artificial* de la UNESCO (2021) y el marco de equidad algorítmica de Barocas, Hardt y Narayanan (2023), que en la práctica se traducen en decisiones puntuales: Grad-CAM para explicar predicciones y auditoría desagregada del desempeño.

Se entrega además el pseudocódigo del entrenamiento, un plan de pruebas en cuatro niveles y una reflexión honesta sobre lo que sé que todavía me falta resolver.

Palabras clave — aprendizaje profundo · redes neuronales convolucionales · transfer learning · inspección visual automatizada · panadería artesanal · ética algorítmica · EfficientNet · control de calidad alimentaria.

02 Identificación y justificación del problema

2.1 Contexto del sector panadero-pastelero en Colombia

La panadería y la pastelería artesanal son uno de los oficios más vivos de la microempresa colombiana. Según cifras de la Federación Nacional de Industriales de la Panadería recogidas por la Cámara de Comercio de Bucaramanga, en Santander operan más de 2.300 establecimientos de panadería formal, y cerca del 78% de ellos son negocios pequeños con menos de diez empleados. En todos esos talleres, el control de calidad lo hace una persona: el maestro panadero, la pastelera, o el operario que al final de la hornada decide qué piezas se venden, cuáles se reprocesan y cuáles van a la basura.

Esto, en sí mismo, no es un problema. El ojo entrenado funciona bastante bien cuando la producción es manejable. Pero deja de funcionar cuando hay tres turnos seguidos, cuando el personal rota cada pocos meses, o cuando uno está cansado al final del día.

Llevo cuatro años trabajando en panadería y pastelería en el Área Metropolitana de Bucaramanga. Hay una escena que se me repite en la cabeza: sábado a las seis de la mañana, dos hornos llenos, fila de clientes esperando el pan caliente. En ese momento nadie está revisando pieza por pieza. Los panes salen, se acomodan en la vitrina y se venden. El lunes vuelve un cliente con un pan medio crudo por dentro y uno se pregunta cómo se nos pasó. La respuesta casi siempre es la misma: estábamos cansados.

OBSERVACIÓN DE CAMPO · EVIDENCIA EMPÍRICA DEL PROBLEMA

Durante el primer trimestre de 2026 hice un seguimiento informal sobre una producción semanal de aproximadamente 3.500 unidades entre pan francés y croissant. La tasa de productos con defectos visuales detectables (sobrecocción, subcocción, deformación, exceso de harina y aglutinamiento) rondaba el 6,8%. De ese porcentaje, alrededor del 31% no se detectaba en la inspección final y llegaba al cliente. Las devoluciones y los reclamos asociados representaron cerca del 2,1% de los ingresos del periodo. No es un número escandaloso, pero para un negocio con márgenes ajustados sí es plata que se está yendo.

2.2 Formulación del problema

Sobre lo anterior, el problema se puede plantear así:

¿Cómo diseñar un algoritmo de aprendizaje profundo capaz de clasificar automáticamente productos de panadería y pastelería como aceptables o defectuosos, identificando además el tipo de defecto, con un nivel de exactitud superior al de la inspección humana en condiciones de producción artesanal y con recursos computacionales accesibles para una microempresa?

Técnicamente, el problema admite dos formulaciones que se complementan. La primera es una clasificación binaria entre **apto** y **defectuoso**, útil como primer filtro en línea de producción. La segunda es una clasificación multiclase entre **apto**, **sobrecocción**, **subcocción**, **deformación**, **exceso de harina** y **aglutinamiento**, que sirve para alimentar tableros de control y entender qué tipo de defecto está fallando más en cada turno o en cada horno.

2.3 Justificación e impacto esperado

Elegí este problema por tres razones concretas: es relevante, es actual y todavía nadie lo ha resuelto bien para el contexto en el que yo trabajo.

Relevancia. El sector panadero colombiano genera, según el DANE, más de 400.000 empleos directos. Un sistema de inspección automatizado, escalable y barato, puede mover la aguja en la rentabilidad de miles de microempresas porque reduce las pérdidas por producto no conforme y baja las devoluciones. Y hay un beneficio menos visible pero igual de importante: la trazabilidad. Cuando se digitaliza la inspección, queda un registro de qué tipo de defectos ocurren, en qué horno, en qué turno. Esa información, que hoy se pierde, es la base para mejorar el proceso de horneado de forma sostenida.

Actualidad. La revisión bibliográfica que viene en la sección siguiente muestra que la inspección visual con aprendizaje profundo es un campo activo y maduro. Trabajos publicados entre 2021 y 2025 reportan exactitudes superiores al 96% en problemas parecidos: detección de defectos en huevos, en gomitas, en sellado de empaques termoformados, en frutas y verduras. Lo que llamó mi atención al revisar la literatura es que casi no hay estudios enfocados en panadería artesanal latinoamericana. Nada sobre pan francés, nada sobre almojábanas, nada sobre las variedades regionales que se hornean cada mañana en Santander. Es una brecha real.

Necesidad de innovación. Las soluciones comerciales de inspección visual que existen están pensadas para grandes plantas industriales, con inversiones que arrancan en cuarenta millones de pesos y pueden llegar a doscientos. Para una panadería de barrio, esos números son inalcanzables. Hay una distancia enorme entre lo que la academia ya sabe hacer y lo que el sector productivo regional puede adoptar. El diseño que propongo busca cerrar esa distancia con una arquitectura ligera, basada en transferencia de conocimiento, que alcanza buenas exactitudes con conjuntos de datos pequeños y hardware modesto: una cámara web decente y un computador de oficina son suficientes para empezar.

03 Revisión bibliográfica

La revisión bibliográfica la abordé siguiendo una estrategia inspirada en el protocolo PRISMA, con búsquedas en Scopus, ScienceDirect, IEEE Xplore y Springer Link, restringidas al periodo 2018-2025 y filtradas con las palabras clave *deep learning*, *convolutional neural networks*, *food defect detection*, *transfer learning* y *algorithmic fairness*. Me concentré en publicaciones revisadas por pares con pertinencia directa al diseño que estoy proponiendo, dejando de lado los trabajos puramente teóricos.

3.1 Redes neuronales convolucionales en inspección alimentaria

Goodfellow, Bengio y Courville (2016) establecen los fundamentos teóricos del aprendizaje profundo y caracterizan a las redes convolucionales como la arquitectura por excelencia para el procesamiento de datos con estructura espacial bidimensional, lo que las convierte en la elección natural para imágenes alimentarias. En esta misma línea, Niel-

sen (2015) ofrece una explicación accesible del proceso de propagación hacia atrás y de la importancia de las funciones de activación no lineales para que las CNN logren modelar relaciones complejas.

El estudio de Cuevas-Velasquez y colegas, publicado en *Scientific Reports*, demostró que arquitecturas profundas como ResNet50, VGG19 y especialmente DenseNet161 preentrenadas sobre ImageNet logran tasas de falsos positivos inferiores al 0,3% y tasas de falsos negativos cercanas al cero en el control de calidad de empaques alimentarios termoformados. Estos resultados sustentan empíricamente la decisión de partir de un modelo preentrenado en lugar de entrenar desde cero, especialmente cuando los conjuntos de datos disponibles son moderados, como suele ocurrir en escenarios de producción artesanal.

Una revisión sistemática reciente, publicada en la revista *Foods* (MDPI, 2025) bajo el título *Machine Learning for Quality Control in the Food Industry: A Review*, analizó 124 publicaciones entre 2005 y 2025 y concluyó que las CNN dominan los enfoques actuales en inspección visual de alimentos, con aplicaciones documentadas en la detección de magulladuras en frutas, decoloraciones en carnes, defectos de empaque y, de manera incipiente, irregularidades en panadería. Esta revisión reporta el caso de Chen y colegas, quienes desarrollaron un sistema de detección de defectos en gomitas con YOLOv3 sobre un conjunto de cinco mil imágenes ampliadas mediante aumento de datos hasta veinte mil muestras, alcanzando exactitudes superiores al 95%.

3.2 Transfer learning y arquitecturas EfficientNet

El transfer learning, o aprendizaje por transferencia, consiste en aprovechar el conocimiento adquirido por un modelo entrenado en un dominio amplio (como ImageNet con sus catorce millones de imágenes y mil clases) para resolver una tarea específica con un conjunto de datos reducido. Esta estrategia es particularmente valiosa cuando recolectar datos etiquetados es costoso o lento, como ocurre en el contexto de una panadería artesanal.

Tan y Le, en el trabajo seminal donde proponen la familia EfficientNet, introducen el concepto de *compound scaling*, una técnica que escala simultáneamente la profundidad, el ancho y la resolución de la red de manera balanceada. El resultado es una familia de modelos que, con menos parámetros que ResNet50 o VGG19, logran exactitudes superiores en ImageNet. EfficientNet-B0, la variante más ligera de la familia, contiene aproximadamente 5,3 millones de parámetros, una cifra que la hace viable para inferencia en hardware modesto, incluyendo dispositivos de borde como tabletas o computadoras de bajo costo.

Estudios aplicados confirman estas cifras. Una investigación publicada en el *International Journal of Intelligent Information Systems* (2024) reporta que EfficientNet-B0, con ajuste fino sobre el conjunto Food-101, alcanza una exactitud del 97,54% en cinco épocas de entrenamiento, superando a MobileNetV2, InceptionV3 y ResNet50 en el mismo escenario. Otro trabajo más reciente, publicado por Rokhva y colegas, integra Efficient-

tNet-B7 con el módulo de atención CBAM y aumento de datos para alcanzar una exactitud del 96,40% en clasificación alimentaria, demostrando que la combinación de transfer learning, atención y regularización es una receta consistente.

UNA DECISIÓN QUE TODAVÍA NO TENGO CERRADA

Después de leer estos trabajos me quedé con la duda de si vale la pena saltar a EfficientNet-B3 o B4 (versiones más grandes pero todavía manejables) para ganar un par de puntos de exactitud, o si quedarse en B0 por la velocidad de inferencia es mejor. La literatura no me dio una respuesta definitiva porque depende mucho del tamaño del dataset final. Mi plan es probar B0 primero como línea base y, si las métricas se quedan cortas, escalar. Esa decisión la tomaría junto con el docente y, eventualmente, con un maestro panadero que pueda decirme qué tipos de defecto son más difíciles de distinguir a simple vista.

3.3 Consideraciones éticas y de equidad algorítmica

El uso de algoritmos de aprendizaje profundo en decisiones que afectan a personas y procesos productivos exige una reflexión ética que no puede limitarse al desempeño técnico. Barocas, Hardt y Narayanan (2023), en *Fairness and Machine Learning: Limitations and Opportunities*, advierten que un modelo puede ser estadísticamente exacto en agregado pero injusto en sus efectos diferenciales sobre subgrupos. Trasladado al contexto de este trabajo, esto implica preguntarse, por ejemplo, si el modelo presenta tasas de error diferenciadas según el tipo de pan, según el horno utilizado o según el turno del operario que tomó la fotografía.

Buolamwini y Gebru (2018), en su célebre estudio *Gender Shades*, demostraron empíricamente que sistemas comerciales de clasificación visual presentan diferencias de exactitud de hasta 34 puntos porcentuales entre subgrupos demográficos. Aunque el escenario de panadería no involucra rostros humanos, la lección metodológica es transferible: es necesario auditar el desempeño del modelo no solo en términos globales sino también desagregado por categorías relevantes del dominio.

La *Recomendación sobre la ética de la inteligencia artificial* de la UNESCO (2021) ofrece un marco normativo internacional que establece principios como la transparencia, la explicabilidad, la rendición de cuentas y la equidad. En el diseño aquí propuesto, estos principios se concretan en tres decisiones específicas: la generación de mapas de activación tipo Grad-CAM para visualizar qué regiones de la imagen llevaron al modelo a su decisión, la documentación del conjunto de datos mediante una *Model Card* al estilo de Mitchell et al. (2019), y la evaluación desagregada del desempeño por tipo de producto.

SÍNTESIS DE LA REVISIÓN

La literatura consultada permite tomar tres decisiones de diseño con respaldo empírico: **(i)** partir de una arquitectura preentrenada en ImageNet en lugar de entrenar desde cero; **(ii)** seleccionar EfficientNet-B0 como punto de partida por su balance entre exactitud y costo computacional; y **(iii)** incorporar mecanismos de explicabilidad y auditoría desagregada como prácticas no negociables del ciclo de desarrollo.

Una limitación honesta de esta revisión: la mayor parte de los trabajos que encontré son sobre frutas, verduras, productos empacados o gomitas. Estudios específicos sobre panadería artesanal son muy escasos, y sobre variedades regionales latinoamericanas prácticamente no hay nada. Esto significa que voy a estar transfiriendo conocimiento de dominios cercanos pero no idénticos, y eso es una fuente de incertidumbre que vale la pena nombrar.

04 Diseño del algoritmo

4.1 Arquitectura general del sistema

La solución se concibe como un sistema modular de seis bloques funcionales que abarcan desde la captura de la imagen hasta la decisión final y la retroalimentación al operario. La figura 1 representa el flujo completo en dark mode, siguiendo la convención visual de paneles industriales modernos.




FIGURA 1. Arquitectura general del sistema Deep Bakery-QC. Cada bloque del pipeline es desacoplable y puede ser reemplazado sin afectar al resto, una propiedad relevante para el mantenimiento y la evolución del modelo.

4.2 Datos de entrada y preprocesamiento

El conjunto de datos previsto contempla la recolección de aproximadamente cuatro mil imágenes de productos de panadería, distribuidas de manera no uniforme entre las seis clases definidas. Cada imagen se captura en formato RGB con resolución mínima de 1280×720 píxeles, sobre un fondo neutro y con iluminación frontal LED de temperatura de color 5000 K, condiciones que replican el escenario de inspección final en un taller artesanal estándar. Posteriormente las imágenes se redimensionan a 224×224 píxeles para su ingreso a la red.

Clase	Cantidad estimada	Descripción
APTO	1.500	Producto que cumple los criterios de color, forma y estructura del estándar interno.
SOBRECOCIÓN	500	Coloración oscura excesiva, corteza quemada o pérdida de brillo.
SUBCOCCIÓN	500	Tono pálido, textura cruda en superficie, ausencia de dorado.
DEFORMACIÓN	500	Pérdida de simetría, hundimiento, abolladura o crecimiento asimétrico.
EXCESO DE HARINA	500	Acumulación visible de harina en superficie, manchas blancas no uniformes.
AGLUTINAMIENTO	500	Dos o más piezas unidas por fusión durante el horneado.

TABLA 1. Distribución del conjunto de datos por clase. Se observa un desbalance esperable, ya que en producción real la clase mayoritaria es siempre la de productos aptos.

Para mitigar el desbalance entre clases y aumentar la robustez del modelo se aplica una estrategia de aumento de datos sobre las clases minoritarias. Las transformaciones contempladas son: rotaciones aleatorias en el rango $\pm 15^\circ$, volteos horizontales, ajustes de brillo y contraste en el rango $\pm 20\%$, recortes aleatorios y zoom en el rango $\pm 10\%$. Esta práctica está respaldada por Chen y colegas, quienes ampliaron un conjunto de cinco mil imágenes de gomitas hasta veinte mil mediante técnicas similares con resultados favorables.

4.3 Arquitectura de la red neuronal

La red propuesta consta de dos bloques diferenciados. El primero corresponde al extractor de características, que reutiliza la arquitectura EfficientNet-B0 con sus pesos preentrenados sobre ImageNet. Durante la primera fase del entrenamiento estas capas se mantienen congeladas para preservar los filtros de bajo y medio nivel ya aprendidos (bordes, texturas, patrones de color). El segundo bloque, denominado cabeza de clasificación, es una red densa específica para el problema de panadería que se entrena desde cero y reemplaza la salida original de mil clases de ImageNet por una salida adaptada a las seis clases del problema.

Capa	Tipo	Salida	Parámetros	Activación
Entrada	Tensor RGB	(224, 224, 3)	—	—
Backbone	EfficientNet-B0	(7, 7, 1280)	4.049.564	Swish
Pooling	GlobalAveragePooling2D	(1280,)	0	—
Dropout-1	Dropout (p=0,3)	(1280,)	0	—
Densa-1	Fully connected	(256,)	327.936	ReLU
Dropout-2	Dropout (p=0,4)	(256,)	0	—
Salida	Fully connected	(6,)	1.542	Softmax
Total entrenable (base de ajuste fino)			329.478	—

TABLA 2. Especificación capa por capa de la arquitectura propuesta.

4.4 Funciones de activación y técnicas de optimización

La elección de las funciones de activación responde a criterios técnicos respaldados por la literatura. En el extractor de características se conserva la función Swish, definida como $f(x) = x \cdot \sigma(x)$, propia de EfficientNet, ya que su naturaleza suave y no monótona facilita el flujo del gradiente en redes profundas. En la capa densa intermedia se utiliza ReLU, que ha demostrado convergencia rápida en problemas de clasificación supervisada. Finalmente, en la salida se emplea Softmax, que produce una distribución de probabilidad sobre las seis clases y permite interpretar la confianza del modelo en cada predicción.

$$\text{Softmax}(z_i) = e^{z_i} / \sum_{j=1}^K e^{z_j} \quad \text{con } K = 6 \text{ clases}$$

Como función de pérdida se utiliza la entropía cruzada categórica, estándar para clasificación multiclase. El optimizador seleccionado es Adam con tasa de aprendizaje inicial de 1×10^{-4} durante la fase de entrenamiento de la cabeza, reducida a 1×10^{-5} durante la fase de ajuste fino, momento en el que se descongelan las últimas veinte capas del backbone. Esta estrategia escalonada, conocida como *fine-tuning progresivo*, está respaldada por las observaciones empíricas reportadas en el estudio de Cuevas-Velasquez sobre control de calidad en empaques alimentarios, donde la descongelación gradual produjo mejoras consistentes sobre el entrenamiento desde cero.

Para combatir el sobreajuste, además del dropout incorporado en la cabeza de clasificación, se aplican las siguientes estrategias: (i) parada temprana basada en la pérdida del conjunto de validación, con paciencia de cinco épocas; (ii) regularización L2 sobre los pesos de las capas densas con coeficiente 1×10^{-4} ; y (iii) reducción adaptativa de la tasa de aprendizaje cuando la métrica de validación no mejora durante tres épocas consecutivas.

4.5 Pseudocódigo del entrenamiento

ALGORITMO 1 · ENTRENAMIENTO DEL MODELO DEEP-BAKERY-QC

```

# Entrada: D_train, D_val, D_test (conjuntos de datos etiquetados)
# Salida: modelo entrenado M*, métricas de evaluación E

función entrenar_modelo(D_train, D_val, D_test):

    # 1. Construcción de la arquitectura
    backbone ← EfficientNetB0(pesos="imagenet", incluir_top=False)
    backbone.entrenable ← False
    cabeza ← construir_cabeza(num_clases=6, dropout=[0.3, 0.4])
    M ← componer(backbone, cabeza)

    # 2. Configuración del optimizador y métricas
    M.compilar(
        optimizador = Adam(lr=1e-4),
        perdida = "entropia_cruzada_categorica",
        metricas = ["exactitud", "precision", "recall", "f1"]
    )

    # 3. Aumento de datos y balanceo de clases
    aug ← DataAugmentation(rotacion=15, flip_h=True,
                           brillo=0.2, zoom=0.1)
    pesos_clase ← calcular_pesos_balanceados(D_train.etiquetas)

    # 4. Fase 1 · Entrenamiento de la cabeza (transfer learning)
    para epoca en rango(1, 21):
        para lote en aug.aplicar(D_train):
            grad ← backpropagation(M, lote, pesos_clase)
            M ← Adam.aplicar(M, grad)
        si parada_temprana(M, D_val, paciencia=5):
            romper

    # 5. Fase 2 · Ajuste fino progresivo
    backbone.descongelar_ultimas(20)
    M.recompilar(optimizador=Adam(lr=1e-5))
    para epoca en rango(1, 11):
        M ← entrenar_epoca(M, D_train, D_val)
        si val_loss_no_mejora(paciencia=3):
            lr ← lr × 0.5

    # 6. Evaluación final sobre conjunto de prueba
    E ← evaluar(M, D_test)
    E_desagregada ← evaluar_por_clase(M, D_test)
    mapas_gradcam ← generar_gradcam(M, muestra=D_test.muestrear(50))

    retornar M, E, E_desagregada, mapas_gradcam

```

05 Implementación y plan de pruebas

El plan de pruebas lo organicé en cuatro niveles, escalando desde la verificación unitaria hasta la validación en condiciones de producción simulada. La estructura no se me ocurrió de la nada: viene de mi rol en la línea ADSO, que en la práctica significa que

vivo revisando entregas y siguiendo fechas en el AVA. Después de un par de años haciendo eso, uno aprende que las cosas se rompen donde uno no se imagina, y que la única forma de evitarlo es probar en pasos pequeños antes de declarar algo terminado.

Nivel	Tipo de prueba	Propósito	Métrica objetivo
1	Unitarias del pipeline de datos	Verificar que el preprocesamiento normaliza y redimensiona correctamente.	Cobertura $\geq 90\%$
2	Validación cruzada $k=5$	Estimar la varianza del modelo y la robustez frente a particiones distintas.	Desv. estándar exactitud $\leq 0,02$
3	Evaluación holdout	Medir desempeño global sobre conjunto de prueba no visto.	F1 macro $\geq 0,90$
4	Auditoría desagregada	Detectar disparidades de desempeño entre subgrupos (tipo de pan, horno, turno).	Diferencia F1 entre subgrupos $\leq 0,05$

TABLA 3. Plan de pruebas en cuatro niveles, con métricas objetivo derivadas de los reportes de la literatura revisada.

$\geq 0,93$ EXACTITUD ESPERADA	$\geq 0,90$ F1-SCORE MACRO	$\leq 5\%$ FALSOS NEGATIVOS	~ 30 ms LATENCIA INFERENCIA
---	---	--	---

Las métricas no son arbitrarias. La exactitud sola, aunque es la más popular, puede ser engañosa cuando hay desbalance de clases, así que la complemento con el F1-score macro, que pondera por igual el desempeño en cada clase sin importar qué tan frecuente sea. La tasa de falsos negativos es la métrica más crítica en este escenario: un falso negativo es un producto malo que llegó al cliente, mientras que un falso positivo es solo una pieza buena que se reprocesa. El costo no es el mismo, y eso debe reflejarse en cómo se ajusta el modelo.

5.1 Casos de prueba específicos del dominio

Más allá de las métricas agregadas, planeo someter el modelo a un conjunto de pruebas pensadas para los casos donde sé que la inspección humana suele fallar. En términos simples, son los escenarios donde uno como panadero también dudaría:

- **Pruebas en condiciones de iluminación variable.** Capturar el mismo lote de productos con tres fuentes de luz distintas (LED frío, luz natural de ventana, luz cálida) y verificar que la predicción se mantenga estable. Tolerancia esperada: variación de F1 menor a 0,03 entre condiciones.

- **Pruebas con productos en frontera.** Curar un subconjunto de cincuenta imágenes que incluso panaderos experimentados clasifican de forma distinta entre sí (los famosos "casos límite"). El modelo debe acompañar su predicción con un nivel de confianza bajo en estos casos, lo que permitiría escalarlos a revisión humana.
- **Pruebas adversarias suaves.** Aplicar perturbaciones pequeñas a las imágenes (ruido gaussiano leve, desenfoque de movimiento) para verificar que el modelo no colapse ante condiciones realistas de captura en línea de producción.
- **Pruebas de regresión.** Cada vez que se reentrene el modelo con datos nuevos, ejecutar el conjunto completo de pruebas anterior para asegurar que no haya retroceso en las clases ya aprendidas.

Esta batería de pruebas no es estándar en la mayoría de los trabajos académicos que revisé, y ahí está parte del valor: en producción real, las métricas globales no cuentan toda la historia.

06 Evaluación crítica y reflexión

El diseño que propuse tiene respaldo bibliográfico y un plan de pruebas estructurado, pero sería deshonesto no nombrar sus limitaciones. La primera tiene que ver con los datos. Aun con técnicas de aumento, cuatro mil imágenes son pocas frente a los millones que manejan los proyectos industriales. La segunda es la sensibilidad del modelo a las condiciones de captura: si cambia la iluminación, el fondo o el ángulo de la cámara, el desempeño puede caer. En la literatura a esto le llaman *distribution shift* y es uno de los problemas que más le pega a los modelos en producción real.

La tercera limitación es de orden ético y, en mi opinión, la más interesante. Las redes profundas son cajas negras. Aunque incorporé Grad-CAM para mitigar esa opacidad, lo que se obtiene es una explicación aproximada y posterior a la decisión, no una trazabilidad lógica como la que ofrecen los sistemas expertos descritos en la guía de la unidad. Esto importa porque, si en algún momento alguien quisiera usar este modelo para evaluar el desempeño de los operarios (cosa que el diseño desaconseja explícitamente), habría que tener mucho cuidado con las implicaciones laborales.

De estas limitaciones salen tres líneas de mejora concretas para próximas iteraciones. **Primero**, un esquema híbrido que combine la red convolucional con un sistema de reglas hechas con maestros panaderos, recuperando la idea de los sistemas expertos descritos por Palma Méndez (2008) para los casos en que la red no esté segura. **Segundo**, técnicas de aprendizaje continuo que le permitan al modelo adaptarse a productos nuevos sin olvidar los anteriores, lo que en la literatura se llama *catastrophic forgetting*. **Tercero**, un protocolo de auditoría periódica que verifique tanto el desempeño global como las posibles disparidades entre subgrupos, en línea con la propuesta de Mitchell et al. (2019) sobre *Model Cards*.

07 Conclusiones

Este trabajo abordó el diseño de un algoritmo de aprendizaje profundo para detectar defectos en productos de panadería y pastelería en el contexto de la microempresa artesanal del Área Metropolitana de Bucaramanga. La propuesta partió de un problema que conozco de primera mano y se articuló con la literatura científica más reciente sobre inspección visual automatizada en alimentos.

El diseño se concretó en una arquitectura modular basada en EfficientNet-B0 con transferencia de conocimiento desde ImageNet, complementada con una cabeza de clasificación específica para seis categorías de defectos. Cada decisión, desde el *backbone* hasta el optimizador, se justificó con evidencia publicada entre 2021 y 2025. En términos simples, el modelo aprende a diferenciar cuándo un producto se ve bien y cuándo no, apoyándose en lo que otras redes ya aprendieron antes sobre millones de imágenes.

No quería que la sección de ética fuera un adorno, sino que se notara en decisiones reales del diseño. Por eso la traduje en cosas concretas: explicabilidad con Grad-CAM, auditoría desagregada por subgrupos y documentación tipo *Model Card*. Esto está bien respaldado en la literatura y, en la práctica, suele mejorar bastante la confianza que un usuario final puede tener en el sistema.

Hay algo que todavía no tengo del todo claro: cuál sería el mejor balance entre exactitud técnica y velocidad de inferencia para una panadería de barrio. Sospecho que la respuesta no es la misma para una pastelería que produce trescientas unidades al día que para una panadería que saca tres mil. Esa pregunta se contesta probando, no leyendo papers.

Como reflexión final, este ejercicio me permitió articular dos mundos que en mi día a día parecen estar en orillas distintas. Por un lado, la pastelería, con su tradición y su saber tácito, ese conocimiento que se aprende mirando, oliendo y tocando, que difícilmente se escribe en un manual. Por el otro, la ingeniería de software, con sus métodos formales y su gusto por las cosas medibles.

Lo que descubrí escribiendo este documento es que no se oponen. El conocimiento del oficio, de hecho, es uno de los insumos más valiosos para diseñar una solución de inteligencia artificial que de verdad sirva. Sin saber cómo huele un pan que está a punto de quemarse, no sabría qué clases definir, qué tan crítica es la sobrecocción frente a la subcocción, ni por qué la auditoría desagregada por horno tiene sentido. Esa es, creo, la lección más útil que me llevo del proceso.

08 Referencias bibliográficas

Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and machine learning: Limitations and opportunities*. MIT Press. <https://fairmlbook.org>

- Bender, E. M., Gebru, T., McMillan-Major, A., & Mitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT)*. <https://doi.org/10.1145/3442188.3445922>
- Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. *Proceedings of Machine Learning Research*, 81, 1-15.
- Cuevas-Velasquez, H., Gallego, A. J., Tiwari, R. P., & Hyttinen, J. (2021). Deep learning for the quality control of thermoforming food packages. *Scientific Reports*, 11, 21887. <https://doi.org/10.1038/s41598-021-01254-x>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. <https://www.deeplearningbook.org>
- Huang, X., Zhang, K., Liu, Y., et al. (2024). Research progress on machine learning and computer vision technology in food quality evaluation. *Food Science*, 45(12), 1-10. <https://doi.org/10.7506/spkx1002-6630-20240131-284>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2.^a ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- Mitchell, M., Wu, S., Zaldivar, A., et al. (2019). Model cards for model reporting. *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency (FAT*)*, 220-229. <https://doi.org/10.1145/3287560.3287596>
- Nielsen, M. (2015). *Neural networks and deep learning*. Determination Press. <http://neural-networksanddeeplearning.com>
- Palma Méndez, J. T. (2008). *Inteligencia artificial: Métodos, técnicas y aplicaciones*. McGraw-Hill.
- Rokhva, S., Teimourpour, B., & Soltani, A. H. (2024). Accurate and real-time food classification through the synergistic integration of EfficientNetB7, CBAM, transfer learning, and data augmentation. *Smart Agricultural Technology*, 9. <https://doi.org/10.1016/j.atech.2024.100628>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning, PMLR*, 97, 6105-6114.
- UNESCO. (2021). *Recomendación sobre la ética de la inteligencia artificial*. UNESCO. https://unesdoc.unesco.org/ark:/48223/pf0000380455_spa
- World Economic Forum. (2020). *The future of jobs report 2020*. World Economic Forum.
- Zhao, M., Chen, Y., Wei, S., et al. (2025). Machine learning for quality control in the food industry: A review. *Foods*, 14(19), 3424. <https://doi.org/10.3390/foods14193424>